

Projektdokumentation: Brustkrebsklassifizierung mittels MLP und Gradio-Schnittstelle

Im Allgemeinen

Das Projekt umfasst ein mehrschichtiges Perzeptron (MLP), das auf der Basis des **Breast-Cancer-Wisconsin**-Datensatzes ein binäres Klassifizierungsproblem löst. Zu dem Projekt gehören:

- Das L2-Regularisierungsmodell von MLP.
- Um eine Überanpassung zu vermeiden, sollten Sie darauf achten.
- Gradio-Interface, mit dem Hyperparameter dynamisch verwaltet werden können und Vorhersagen anhand einzelner Beispiele getestet werden.

Erklärung der Daten

569 Datenproben mit 30 Merkmalen und einem binären Ziel bilden den Brustkrebsdatensatz:

- 1 – ein gutartiger Tumor.
- 0 - krankhafter Tumor.

Datenmischung: Zur Gewährleistung einer zufälligen Verteilung der Daten, die zu den drei Gruppen gehören:

- Training (70%)
- Validierung (15%)
- Test (15%)

Datennormalisierung bezeichnet die Umsetzung von Merkmalen auf denselben Maßstab.

Erläuterung des Modells der MLP

Eingabe-Level mit 30 Funktionen (Eingabedaten). 64 Neuronen (ReLU-Aktivierung + L2-Regularisierung) sind die beiden verborgenen Ebenen. 32 Nervenzellen (Aktivierung der ReLU und Regularisierung der L2). Ein Neuron (Sigmoid-Aktivierung zur binären Klassifizierung) ist in der Ausgabeschicht vorhanden.

Modellierung von Hyperparametern

Anpassbare Gradio-Einstellungen:

- **L2-Regularisierung:** Um eine Überanpassung zu vermeiden, reduziert sie die Modellkomplexität (Beispiele sind 0,014, 0,06 und 0,048).
- **Lernrate:** Regelt, welche Schrittgröße zur Aktualisierung der Gewichte verwendet wird (Beispiele sind 0,0042 bzw. 0,0058).
- **Optimierer:** Methode zur Optimierung des Gradientenabstieges. Potenzielle Werte sind Adam, SGD und RMSprop.

Frühes Aufhören (Oder Early-Stopping)

Um zu vermeiden, dass eine Überanpassung auftritt, erfolgt eine frühzeitige Beendigung mit den nachfolgenden Parametern. **Monitoring:** `val_loss` (Verlust an Validierung).

Geduldparameter = 5: Wenn der Validierungsverlust innerhalb von fünf Epochen nicht abnimmt, wird das Training beendet. **restore_best_weights** = True: Ersetzt das Modell mit den besten Gewichten.

Gradio-Schnittstelle

Modelltraining ist die wichtigste Funktionalität der Schnittstelle: Sie können die L2-Regularisierung und Lernrate bestimmen und einen Optimierer wählen. Das Ergebnis des Trainings ist die Genauigkeit der Trainingsdaten. Präzision von Validierungsdaten. Die Präzision der Testdaten. Verluste in Bezug auf die Testdaten. Fehler beim Test. Ergebnis (⚠ – bei einer Genauigkeit von weniger als 98 %, ✅ – bei einer Genauigkeit von 98 % oder mehr). Vorhersage anhand einzelner Beispiele: Der Anwender hat die Möglichkeit, aus dem Validierungssatz einen Beispielsindex auszuwählen und erhält: Wahrscheinlichkeit der Klasse 1., die wahre Klasse und Voraussichtliche Klasse

Experimentelle Ergebnisse

	RMSprop	SGD	Adam
L2-Regularisierung	0.014	0.06	0.048
Learning Rate	0.0042	0.0042	0.0058
Trainingsgenauigkeit	98.24%	96.73%	97.99%
Validierungsgenauigkeit	96.47%	95.29%	95.29%
Testgenauigkeit	98.84%	98.84%	98.84%

Testverlust	0.1038	2.8868	0.1467
Testfehler	1.16%	1.16%	1.16%

L2 Регуляризация0,06

Learning Rate0,0042

ОптимизаторSGD

Обучить модель

{} Результаты

1

2

3

4

5

6

7

8

{

"Тренировочная точность": "96.73%",

"Валидационная точность": "95.29%",

"Тестовая точность": "98.84%",

"Тестовый Loss": "2.8868",

"Тестовая погрешность": "1.16%",

"Результат": "✅ Тестовая точность достигнута: 98.84%."

}

Bild 1: SGD

L2 Регуляризация0,048

Learning Rate0,0058

ОптимизаторAdam

Обучить модель

{} Результаты

1

2

3

4

5

6

7

8

{

"Тренировочная точность": "97.99%",

"Валидационная точность": "95.29%",

"Тестовая точность": "98.84%",

"Тестовый Loss": "0.1467",

"Тестовая погрешность": "1.16%",

"Результат": "✅ Тестовая точность достигнута: 98.84%."

}

Bild 2: ADAM

L2 Регуляризация

0,014

Learning Rate

0,0042

Оптимизатор

RMSprop

Обучить модель

Результаты

```

1  {
2    "Тренировочная точность": "98.24%",
3    "Валидационная точность": "96.47%",
4    "Тестовая точность": "98.84%",
5    "Тестовый Loss": "0.1038",
6    "Тестовая погрешность": "1.16%",
7    "Результат": "✅ Тестовая точность достигнута: 98.84%."
8  }

```

Bild 3: *RMSprop*

Es kann auch vorkommen, dass das trainierte Modell eine Testgenauigkeit aufweist, die unter 98 % liegt. Am Beispiel des „Adam“-Optimierers mit den folgenden Parametern erhält man diese Tabelle:

	Adam
L2-Regularisierung	0.1
Learning Rate	0.0001
Trainingsgenauigkeit	94.47%
Validierungsgenauigkeit	94.12%
Testgenauigkeit	93.02%
Testverlust	4.2490
Testfehler	6.98%




Bild 4: ADAM: Testgenauigkeit niedriger als 98%

Schlussfolgerungen

Das MLP-Modell kann mithilfe unterschiedlicher Optimierer- und Hyperparameterkombinationen eine Testgenauigkeit von mehr als 98 % erzielen. Die Lernrate und die L2-Regularisierung beeinflussen das Ergebnis erheblich: Mit einer niedrigeren L2-Regularisierung kann das Modell besser an die Daten angepasst werden. Die Ergebnisse der Optimierer Adam bzw. RMSprop sind stabil. Der Testverlust deutet darauf hin, dass die Verluste des SGD-Optimierers höher sind, aber die Endgenauigkeit bei 98,84 % bleibt.

Beobachtete Effekte

Die **L2-Regularisierung** wirkt sich direkt auf die Komplexität des Modells aus:

- Niedrige Werte der L2-Regularisierung führen dazu, dass das Modell die Trainingsdaten sehr genau anpasst. Dies kann jedoch zu einer ****Überanpassung**** (Overfitting) führen, wodurch die Genauigkeit auf den Testdaten sinkt.
- Hohe Werte der L2-Regularisierung ****vereinfachen das Modell, indem die Gewichtungen der Neuronen stärker reguliert werden. Dadurch sinkt zwar die **Trainingsgenauigkeit**, aber die Generalisierung des Modells verbessert sich, was zu einer besseren Leistung auf den Testdaten führt.**

Die **Lernrate** bestimmt, wie schnell das Modell seine Gewichtungen während des Trainings aktualisiert:

- Eine niedrige Lernrate führt zu einer langsameren, aber stabileren Konvergenz. Das Training dauert länger, erzielt jedoch präzisere Ergebnisse.
- Eine hohe Lernrate beschleunigt das Training, birgt aber die Gefahr von **instabilen Schwankungen** und einem Verfehlen des optimalen Lösungsbereichs.

Die Wahl des **Optimierers** beeinflusst die Art und Weise, wie die Gewichtungen im neuronalen Netzwerk aktualisiert werden:

1. Adam:

- Der Adam-Optimierer kombiniert die Vorteile von Momentum und RMSprop.
- Er passt die Lernrate für jede Gewichtung adaptiv an und erzielt dadurch schnell und zuverlässig gute Ergebnisse.
- In diesem Datensatz liefert Adam eine **stabile Konvergenz** und hohe Genauigkeit, wie in den Screenshots zu sehen.

2. RMSprop:

- Dieser Optimierer ist besonders effektiv bei Daten, deren Merkmale unterschiedliche Maßstäbe haben.
- Er erreicht gute Ergebnisse, benötigt aber eine feine Abstimmung der Lernrate, um stabil zu arbeiten.

3. SGD:

- Der klassische SGD-Optimierer zeigt eine **langsamere Konvergenz** im Vergleich zu Adam und RMSprop. Trotz etwas höherer Verluste während des Trainings gelingt es SGD, eine hohe Testgenauigkeit zu erreichen (wie in den Screenshots dargestellt).

Das **frühzeitige Stoppen (Early-Stopping)** verhindert Überanpassung (Overfitting), indem das Training gestoppt wird, sobald der Validierungsverlust nicht weiter abnimmt. In der implementierten Lösung wird Early Stopping mit der Option ``restore_best_weights=True`` verwendet. Dadurch werden die Gewichte des Modells auf den Zustand zurückgesetzt, der die niedrigste Validierungsverlustfunktion erreicht hat. Dieses Verfahren sorgt dafür, dass das Modell nicht unnötig lange trainiert und eine gute Balance zwischen Trainings- und Testleistung erreicht wird.

Die Ergebnisse zeigen, dass das Modell in der Lage ist, eine Testgenauigkeit von ****98,84 %**** zu erreichen, unabhängig von den eingesetzten Optimierern. Hierbei haben unterschiedliche Kombinationen aus ****L2-Regularisierungswerten**** und ****Lernraten**** einen Einfluss auf die Trainings- und Validierungsverluste:

- Adam: Stabilste und schnellste Konvergenz bei hoher Testgenauigkeit.
- RMSprop: Guter Kompromiss bei komplexeren Daten.
- SGD: Trotz langsamer Konvergenz liefert es verlässliche Ergebnisse bei der Testgenauigkeit.

Die visuelle Darstellung in den Screenshots verdeutlicht die erzielten Resultate und die Auswirkungen der Parameter.

Abschluss

Das MLP-Modell löst das Klassifizierungsproblem erfolgreich und erreicht eine Testgenauigkeit von 98,84 % für verschiedene Parameterkombinationen.